Bagian A: Analisis Konseptual

Nama / NIM: Alexandria Natasya Beslar / 2802471801

1. Efek Regularisasi pada Batch Normalization (Slide 6–8)

Pada fase training, Batch Normalization menormalkan aktivasi tiap channel memakai mean dan varians mini-batch, bukan statistik populasi. Statistik ini hanya estimasi yang berbeda di tiap mini-batch, sehingga keluaran suatu sampel bergantung pada sampel lain dalam batch yang sama. Noise inilah yang bekerja seperti regularisasi ringan (Slide 8), neuron sulit menghafal sampel tertentu atau saling bergantung secara berlebihan (co-adaptation), mirip efek Dropout.

Asumsi bahwa BN menghilangkan kebutuhan Dropout tidak berlaku ketika batch size sangat kecil (misalnya 2–8) karena statistik batch menjadi tidak representatif, sehingga pelatihan tidak stabil dan terjadi ketidakcocokan dengan running statistics saat inference. Hal serupa terjadi bila batch tidak i.i.d. (misalnya berisi satu kelas saja), dan BN saja tidak cukup mencegah overfitting pada head fully connected yang besar. Pada kondisi tersebut digunakan alternatif seperti GroupNorm atau LayerNorm, atau Dropout tetap dipertahankan.

2. Degradasi Jaringan Dalam dan Formulasi Residual (Slide 10–12)

Degradation problem berarti plain CNN yang lebih dalam justru memiliki training error lebih tinggi, sehingga bukan overfitting melainkan kesulitan optimisasi. Secara teori model dalam dapat meniru model dangkal bila layer tambahan menjadi identity mapping, tetapi solver sulit mempelajari identity melalui tumpukan layer non-linear.

Skip connection mengubah formulasi menjadi y = F(x) + x. Layer hanya mempelajari residual F(x) = H(x) − x, dan identity cukup diperoleh dengan mendorong F(x) mendekati nol, yang jauh lebih mudah. Pada backpropagation, $\partial L/\partial x = \partial L/\partial y \cdot (1 + \partial F/\partial x)$, suku "1" menyediakan jalur langsung bagi gradien ke layer awal tanpa dikalikan berulang oleh turunan tiap layer.

Ini berkaitan dengan vanishing gradient (Sesi 02): pada plain network gradien terus dikalikan dan mengecil secara eksponensial terhadap kedalaman, sedangkan skip connection memotong rantai perkalian itu sehingga gradien tetap mengalir. Vanishing gradient hanya salah satu faktor, karena degradation juga terjadi pada jaringan ber-BN.

3. Feature Extraction vs Fine-Tuning (Slide 14–16)

Empat dimensi perbandingan:

- Trainable parameters: Feature Extraction hanya melatih head (pada eksperimen ini 5.130 parameter), sedangkan Fine-Tuning melatih banyak lapisan (8.398.858 parameter pada layer4 + fc).
- Volume data: Feature Extraction cocok untuk data sangat sedikit karena risiko overfitting rendah; Fine-Tuning memerlukan data lebih banyak agar bobot yang dibuka dapat disesuaikan tanpa menghafal.
- Komputasi dan memori: pada Feature Extraction backward pass tidak melewati backbone sehingga lebih hemat; Fine-Tuning memerlukan gradien dan optimizer state untuk lapisan yang dibuka.
- Risiko destructive gradient updates: pada Fine-Tuning, gradien besar dari head yang baru diinisialisasi acak dapat merusak fitur pretrained.

Kriteria praktis: data sedikit atau komputasi terbatas dengan domain mirip ImageNet, pilih Feature Extraction; data cukup atau domain berbeda, pilih Fine-Tuning pada lapisan akhir dengan learning rate kecil.

4. Kaidah Penerapan Data Augmentation (Slide 20, 21, 23)

Augmentasi hanya diaktifkan pada train set karena tujuannya memperkaya variasi data latih sebagai regularisasi. Validation dan test set harus mengukur performa pada distribusi data asli yang tidak

diubah. Bila diaugmentasi, metrik menjadi acak dan berubah di tiap eksekusi sehingga sulit dibandingkan, serta tidak mencerminkan data yang akan dihadapi saat deployment. Menerapkan augmentasi sebelum data dibagi juga dapat membuat versi turunan citra yang sama berada di train dan test (data leakage), sehingga estimasi generalisasi menjadi terlalu optimistis. Validation set juga dipakai untuk early stopping dan pemilihan model, yang membutuhkan evaluasi konsisten.

Contoh transformasi yang tidak layak: ColorJitter dengan perubahan hue besar pada klasifikasi ras hewan peliharaan. Warna dan pola bulu merupakan fitur pembeda ras (misalnya corak colourpoint pada Ragdoll dan Birman), sehingga perubahan hue ekstrem dapat mengubah label semantik dan melanggar invariansi label.

5. Mitigasi Catastrophic Forgetting (Slide 28–29)

Catastrophic forgetting terjadi ketika adaptasi dilakukan terlalu agresif (learning rate besar, terlalu banyak layer dibuka, epoch panjang) pada data baru yang kecil. Gradien dari data baru menimpa bobot layer awal dan tengah yang menyimpan fitur umum hasil pretraining, seperti tepi dan tekstur. Representasi ImageNet berubah drastis dan hilang, sementara model menyesuaikan diri berlebihan pada data kecil.

Dua strategi mitigasi:

1. Differential learning rate: backbone diberi learning rate lebih kecil (misalnya 1e-4) dan head lebih besar (1e-3). Layer awal berisi fitur generik yang tidak perlu banyak berubah, sedangkan layer akhir dan head bersifat spesifik tugas. Strategi ini dipakai pada B3.
2. Gradual unfreezing: head dilatih lebih dulu, lalu layer dibuka bertahap dari atas. Head yang sudah stabil tidak lagi mengirim gradien besar dan acak ke backbone, sehingga fitur pretrained terlindungi.

Referensi

Dr. Hidayaturrahman. (2026). Sesi 05: Advanced CNN's dan Transfer Learning [Slide 5–30]. Deep Learning, BINUS University.