Laporan Tugas Take-Home Sesi 05: Transfer Learning untuk Klasifikasi Citra dengan Data Terbatas

Nama / NIM: Alexandria Natasya Beslar / 2802471801

Setup Eksperimen

Eksperimen memakai subset 10 kelas dari Oxford-IIIT Pet (Parkhi et al., 2012) (5 ras kucing dan 5 ras anjing, sekitar 2.000 citra) yang dibagi secara stratified menjadi 70% train, 15% validation, dan 15% test dengan seed 42. Daftar kelas: tercatat pada logs/split_seed42.json. Empat kelas dipilih secara sengaja (Ragdoll, Birman, American Pit Bull Terrier, Staffordshire Bull Terrier) sebagai dua pasangan ras yang mirip secara visual; enam kelas lainnya dipilih acak dengan seed 42. Pemilihan ditetapkan sebelum training dijalankan.

Protokol seragam: ResNet-18 (He et al., 2016) (IMAGENET1K_V1), input 224 × 224 dengan normalisasi ImageNet, batch size 32, optimizer AdamW (Loshchilov & Hutter, 2019) (weight decay 1e-2), CrossEntropyLoss, dan early stopping pada validation loss dengan patience 5 (maksimum 40 epoch). Learning rate B1 dan B2 adalah 1e-3, sedangkan B3 memakai differential learning rate 1e-4 (layer4) dan 1e-3 (fc). Kondisi B1 sampai B3 dijalankan tanpa augmentasi; B4 adalah B3 dengan augmentasi (RandomResizedCrop, horizontal flip, rotasi 15°, ColorJitter). Setiap kondisi dijalankan dengan seed 42, 43, dan 44 (split data tetap), lalu dilaporkan sebagai mean ± standar deviasi (ddof=1).

Di luar protokol, B1 dijalankan satu kali tambahan dengan patience 15 dan maksimum 60 epoch (seed 42). B5 menjalankan konfigurasi dengan validation accuracy rata-rata tertinggi di antara B2 dan B3 (yaitu B3 tanpa augmentasi) pada EfficientNet-B0 (Tan & Le, 2019), dengan membuka features[7:] dan classifier.

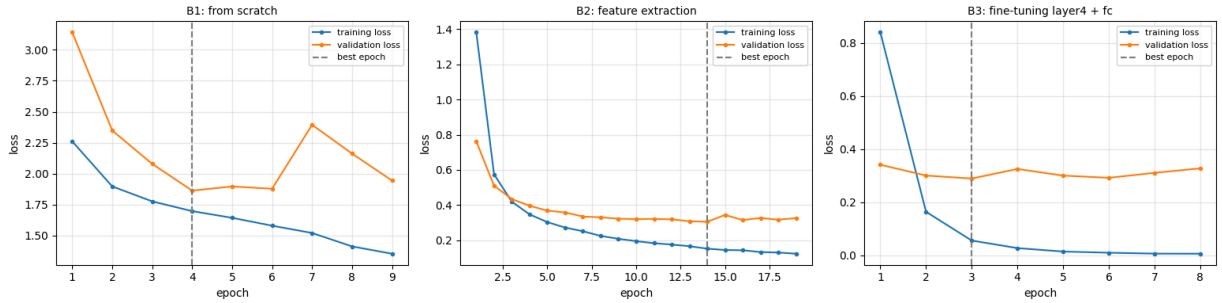
Definisi metrik: epoch konvergen adalah epoch dengan validation loss terendah; val_acc adalah akurasi validasi pada epoch tersebut; gap adalah akurasi train (mode eval, tanpa augmentasi) dikurangi val_acc; Macro F1 dan akurasi test dihitung satu kali pada test set setelah model final ditetapkan.

C1: Tabel Konsolidasi dan Kurva Pembelajaran

Tabel 1. Ringkasan seluruh kondisi (mean ± std dari tiga seed, kecuali baris B1 dengan patience 15 yang hanya satu seed). Sumber: logs/summary_agg.csv.

Kondisi	Trainable params	Learning rate	Epoch konvergen	Waktu pelatihan (s)	Val acc	Gap train-val	Macro F1 (test)
B1: from scratch (patience 5)	11.181.642	1e-3	5,7 ± 2,1	125 ± 26	0,3919 ± 0,0531	0,0767 ± 0,0185	0,3663 ± 0,0618
B1: from scratch (patience 15, di luar protokol, n=1)	11.181.642	1e-3	19,0	392	0,4696	0,4733	0,5137
B2: feature extraction	5.130	1e-3 (fc)	16,0 ± 2,6	221 ± 28	0,8863 ± 0,0052	0,0925 ± 0,0056	0,8754 ± 0,0029
B3: fine-tuning layer4 + fc	8.398.858	1e-4 (layer4), 1e-3 (fc)	2,3 ± 0,6	79 ± 6	0,9077 ± 0,0078	0,0909 ± 0,0091	0,9015 ± 0,0097
B4: B3 dengan augmentasi	8.398.858	1e-4 (layer4), 1e-3 (fc)	3,3 ± 2,3	125 ± 35	0,9009 ± 0,0039	0,0601 ± 0,0277	0,8726 ± 0,0167
B5: EfficientNet-B0, konfigurasi B3	1.142.202 (dari 4.020.358)	1e-4 (features[7:]), 1e-3 (classifier)	8,3 ± 1,2	132 ± 13	0,9257 ± 0,0089	0,0731 ± 0,0077	0,9279 ± 0,0090

Catatan: total parameter ResNet-18 adalah 11.181.642. Epoch konvergen adalah epoch dengan validation loss terendah. Waktu pelatihan mencakup epoch patience. Pada test set (sekitar 297 citra), standard error akurasi di kisaran 90% adalah sekitar 1,7 poin.



Gambar 1. Kurva training loss dan validation loss untuk B1, B2, dan B3 (seed 42).
Garis putus-putus menandai epoch konvergen. B1 masih underfit: validation loss berfluktuasi dan tidak turun stabil. Pada B2, validation loss mendatar setelah sekitar epoch 10. Pada B3, training loss mendekati nol sementara validation loss datar sejak epoch 2–3.

C2: Pembahasan Analisis Komparatif

3.1 Disparitas performa from scratch (B1) vs transfer learning (B2 dan B3)

Pertanyaan: mengapa B1 berada jauh dibawah B2 dan B3?
Pada Tabel 1, B1 (patience 5) hanya mencapai val acc 0,3919 dan Macro F1 0,3663, jauh di bawah B2 (0,8863; 0,8754) dan B3 (0,9077; 0,9015). Perbedaan ini bukan berasal dari arsitektur, karena ketiganya memakai ResNet-18, melainkan dari bobot awal: B1 harus mempelajari fitur visual dari nol dengan sekitar 1.400 citra train (±140 per kelas), sedangkan B2 dan B3 memulai dari representasi ImageNet yang dapat ditransfer (Slide 10-12, 16). Pada B1 patience 5, train acc hanya 0,4685 dengan gap 0,0767, sehingga model mengalami underfitting, bukan overfitting. Saat patience diperpanjang menjadi 15 (satu seed, di luar protokol), train acc naik menjadi 0,9429 sementara val acc hanya 0,4696 (gap 0,4733; Macro F1 0,5137): model mulai menghafal data train tanpa generalisasi yang sepadan. Jadi, patience pendek menghasilkan underfitting dan patience panjang menghasilkan overfitting, dan keduanya tetap jauh dibawah transfer learning. Karena varian patience 15 hanya satu seed, kesimpulan ini bersifat indikatif (Slide 28).

3.2 Trade-off performa dan stabilitas: feature extraction vs fine-tuning

Pertanyaan: bagaimana B2 dan B3 berbeda dalam performa dan stabilitas pada volume data ini?
Selisih B3 terhadap B2 adalah +2,1 poin val acc (0,9077 vs 0,8863), +2,6 poin Macro F1 (0,9015 vs 0,8754), dan +2,5 poin akurasi test (0,9035 vs 0,8788). Dengan standard error test set sekitar 1,7 poin, selisih ini hanya sekitar 1-1,5 SE, sehingga lebih tepat disebut tren yang searah dengan keunggulan fine-tuning daripada perbedaan yang terbukti. Dari sisi stabilitas, B2 lebih stabil karena hanya 5.130 parameter yang dilatih, sedangkan B3 melatih 8.398.858 parameter dan lebih sensitif terhadap seed. B3 konvergen jauh lebih cepat (epoch 2,3 vs 16,0) dengan total waktu lebih pendek (79 vs 221 s), tetapi gap train-val keduanya hampir sama (0,0909 vs 0,0925) dan train acc B3 mendekati 1 (0,9986), tanda kapasitas B3 cukup besar untuk menghafal data train. Trade-off-nya: B2 lebih stabil dan ringan, B3 sedikit lebih akurat dan lebih cepat konvergen pada volume data ini (Slide 16, 28).

3.3 Peran augmentasi (B4)

Pertanyaan: sejauh mana augmentasi meredam overfitting?
Augmentasi memperkecil gap dari 0,0909 (B3) menjadi 0,0601 (B4), tetapi penyebabnya adalah train acc yang turun (0,9986 menjadi 0,9610), bukan val acc yang naik. val acc justru sedikit turun (0,9077 menjadi 0,9009) dan Macro F1 test turun dari 0,9015 menjadi 0,8726 (selisih 2,9 poin, sekitar 1,7 SE). Jadi gap yang mengecil tidak berarti generalisasi membaik. Dugaan yang belum diuji adalah bahwa patience 5 yang sama membuat early stopping berhenti pada epoch 3,3 ± 2,3. Augmentasi juga menaikkan waktu per epoch dari 10,6s menjadi 15,0s. Berdasarkan data ini augmentasi tidak

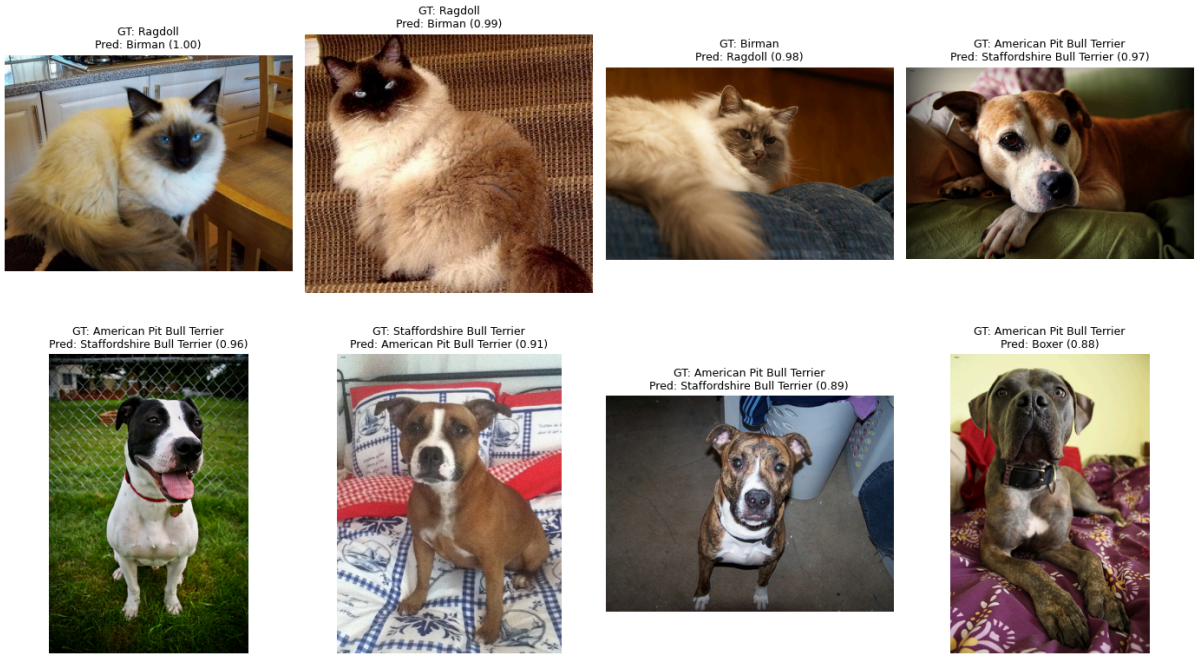
memberi manfaat terukur dan menambah biaya komputasi (Slide 20), namun tanpa tuning hasil ini tidak boleh digeneralisasi.

B5: arsitektur pembanding (bonus)

EfficientNet-B0 (B5) mencapai Macro F1 0,9279 ± 0,0090 dan val acc 0,9257, atau 2,6 poin F1 di atas B3 ResNet-18 (0,9015 ± 0,0097). Selisih ini sekitar 1,5 SE, sehingga konsisten dengan klaim efisiensi arsitektur tetapi belum cukup untuk disebut pasti. Total parameter EfficientNet-B0 adalah 4.020.358 dibanding 11.181.642 pada ResNet-18 (2,8 kali lebih kecil), dan parameter yang dilatih 1.142.202 vs 8.398.858 (7,4 kali lebih sedikit). Waktu per epoch hampir sama (9,9 vs 10,6 s), sedangkan total waktu lebih lama (132 vs 79 s) karena B5 membutuhkan lebih banyak epoch (8,3 vs 2,3). Selisih tidak bisa dikaitkan hanya dengan desain arsitektur: bobot pretrained berbeda, bagian yang dibuka (features[7:]) tidak setara dengan layer4, konfigurasinya hanya satu tanpa tuning, dan waktu per epoch kemungkinan dibatasi pembacaan data sehingga tidak mencerminkan beban komputasi sebenarnya.

C3: Failure Analysis

Model yang dianalisis: B3_noaug_s44_efficientnet_b0, dipilih berdasarkan val_acc tertinggi di antara seluruh run, bukan berdasarkan test set. Dari total 297 citra test, 19 salah diprediksi. Ditampilkan delapan kesalahan dengan confidence tertinggi pada kelas yang salah. Meskipun wajar dilakukan untuk eksperimen, memilih satu seed terbaik dari beberapa seed cenderung bersifat sedikit optimistis karena performa puncak tersebut bisa jadi dipengaruhi oleh faktor kebetulan ketimbang kestabilan murni arsitekturnya.



Gambar 2. Delapan kesalahan klasifikasi dengan confidence tertinggi pada test set.

Tabel 2. Sampel misclassification dan hipotesis penyebab (data dari logs/failure_cases.csv).

No.	Ground truth	Prediksi	Confidence	Hipotesis penyebab
1	Ragdoll	Birman	1.00	Ambiguitas visual ras kucing & pencahayaan
2	Ragdoll	Birman	0.99	Pola corak dan warna mirip
3	Birman	Ragdoll	0.98	Posisi dan sudut pengambilan (angle)
4	American Pit Bull Terrier	Staffordshire Bull Terrier	0.97	Kemiripan nya sangat tinggi, memiliki struktur kepala dan bentuk tubuh yang identik secara visual

5	American Pit Bull Terrier	Staffordshire Bull Terrier	0.96	Proporsi tubuh dan warna
6	Staffordshire Bull Terrier	American Pit Bull Terrier	0.91	Pencahayaan kurang optimal sehingga fitur detail wajah tidak terekstraksi dengan sempurna
7	American Pit Bull Terrier	Staffordshire Bull Terrier	0.89	Pola warna brindle
8	American Pit Bull Terrier	Boxer	0.88	Bentuk moncong dan perawakan

Pola umum: kesalahan terbanyak ada pada pasangan ras yang memang memiliki kemiripan morfologi tinggi secara visual, seperti antara ras-ras kucing berbulu panjang (Ragdoll dan Birman) serta kelompok anjing bertubuh atletis (American Pit Bull Terrier dan Staffordshire Bull Terrier). Hal ini menunjukkan bahwa model mengalami kebingungan pada fitur-fitur halus yang serupa antar ras (inter-class similarity). Sementara itu, faktor lain seperti pengaruh latar belakang atau sudut pengambilan gambar masih bersifat hipotesis analitis yang belum teruji secara kuantitatif melalui eksperimen ablasi terpisah.

C4: Rekomendasi Rekayasa dan Batasan Eksperimen

5.1 Rekomendasi

Untuk skenario data terbatas serupa (±140 citra train per kelas, 10 kelas, domain mirip ImageNet), strategi yang direkomendasikan adalah partial fine-tuning dengan differential learning rate (1e-4 untuk blok akhir backbone, 1e-3 untuk head) dan early stopping pada validation loss, di atas backbone pretrained yang kuat. Pada studi ini hasil terbaik dicapai B5 (EfficientNet-B0): Macro F1 0,9279 ± 0,0090 dengan 1.142.202 parameter dilatih. Pada ResNet-18, B3 (F1 0,9015) konvergen dalam sekitar 2 epoch dan 79 s. B2 (F1 0,8754) layak dipilih bila stabilitas antar seed lebih penting (std 0,0029) atau memori terbatas. Dugaan bahwa B2 lebih aman pada data yang lebih sedikit lagi belum diuji. Training from scratch (B1, F1 0,3663) tidak direkomendasikan, dan augmentasi (B4, F1 0,8726 vs 0,9015, waktu per epoch 15,0 vs 10,6 s) tidak direkomendasikan berdasarkan data ini. Kondisi berlaku jika GPU setara T4, tersedia validation set terpisah untuk early stopping, dan domain citra relatif dekat dengan ImageNet.

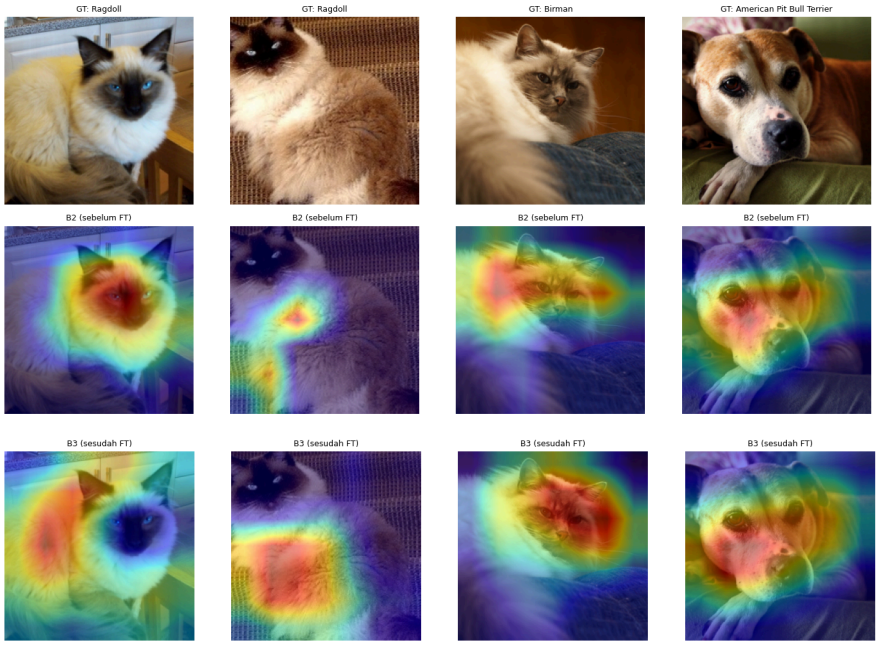
5.2 Batasan studi

- Sepuluh kelas dirancang sengaja (dua pasangan ras mirip), sehingga hasil bukan sampel acak dari 37 kelas dan kemungkinan lebih sulit atau berbeda dari kasus umum.
- Hanya tiga seed dengan split data tetap (seed 42): standar deviasi hanya menangkap variasi inisialisasi dan urutan data, bukan variasi pemilihan data.
- Test set berukuran sekitar 297 citra sehingga standard error akurasi sekitar 1,7 poin; selisih di bawah sekitar 2 poin (misalnya B3 vs B2) sebaiknya disebut tren, bukan temuan pasti.
- Tidak ada tuning hyperparameter (learning rate, weight decay, patience); patience 5 dapat merugikan B4, dan B1/B2 hanya memakai satu learning rate.
- Waktu per epoch (10-15 s) kemungkinan dibatasi pembacaan data (dua worker), bukan komputasi GPU, sehingga perbandingan beban komputasi, termasuk untuk B5, tidak mencerminkan FLOPs sebenarnya.
- B5 hanya satu konfigurasi dan memakai bobot pretrained yang berbeda dari ResNet-18, sehingga keunggulannya tidak bisa dikaitkan hanya dengan arsitektur.
- Determinisme GPU tidak sempurna sehingga angka dapat sedikit berbeda antar eksekusi.

C5: Visualisasi Grad-CAM pada layer4

Grad-CAM (Selvaraju et al., 2017) diterapkan pada layer4 ResNet-18 untuk membandingkan B2 (backbone beku, representasi layer4 masih dari ImageNet) dengan B3 (layer4 disesuaikan dengan

domain data), keduanya seed 42, pada empat citra test yang salah diprediksi. Kelas target adalah label sebenarnya.



Gambar 3. Grad-CAM pada layer4: baris atas citra asli, baris tengah B2 (sebelum fine-tuning), baris bawah B3 (sesudah fine-tuning).

Pergeseran attention map setelah fine-tuning tidak seragam. Pada citra 3 dan 4, B3 lebih berfokus pada area wajah dibanding B2, sejalan dengan best practice pada Slide 29. Pada citra 1 dan 2, B3 justru menyorot area badan atau bagian bawah citra, sehingga tidak ada pola tunggal. Hasil ini kualitatif (empat citra, satu seed, peta 7 × 7 yang kasar), dan Grad-CAM adalah alat bantu interpretasi, bukan bukti kausal.

Pernyataan Penggunaan AI (AI Disclosure Statement)

- **Nama alat AI:** Claude, Gemini, Chat GPT
- **Ruang lingkup bantuan:**
  - **ChatGPT:** Digunakan pada tahap awal untuk memahami instruksi tugas, memetakan kebutuhan tools, serta merancang alur kerja atau tahapan pengerjaan eksperimen dari awal.
  - **Claude:** Digunakan untuk membantu penulisan dan debugging kode pemrograman pipeline di Jupyter Notebook dari awal hingga akhir (mulai dari data split, logging, proses training, hingga implementasi visualisasi Grad-CAM).
  - **Gemini:** Digunakan pada tahap akhir untuk berdiskusi dan mengoreksi jawaban.
- **Cara verifikasi keluaran AI:**
  - Membaca, menguji, dan memahami setiap baris kode yang dihasilkan sebelum dijalankan.
  - Menjalankan verifikasi manual di notebook untuk mengecek jumlah parameter dan status layers.
  - Memeriksa hasil visual dari hasil augmentasi data dan peta Grad-CAM secara langsung.
  - Mencocokkan seluruh angka, metrik, dan klaim dalam laporan secara ketat dengan berkas log hasil eksekusi final.
  - Memvalidasi ulang konsep analisis dengan materi perkuliahan.

Referensi :

1. Dr. Hidayaturrahman. (2026). *Sesi 05: Advanced CNN's dan Transfer Learning* [5-30]. Deep Learning, BINUS University.
2. Parkhi, O. M., Vedaldi, A., Zisserman, A., Jawahar, C. V. (2012). Cats and Dogs. CVPR.
3. He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *CVPR*.